펫 클리닉 3계층 아키텍처 인프라 구축

AWS를 사용한 이중화 설계와 구축, 그리고 문서화

Cloud 9: 김태준(팀장), 김건형, 김승환, 양진현, 우수빈

AI 서비스 운영을 위한 클라우드 데이터 엔지니어 과정 중간 프로젝트

2026. 9. 21. ~ 2026. 10. 14. (13일)

2026. 10. 14. (수) 발표

© 2026 Cloud 9

목차

1. 서비스 시나리오, 팀과 작업 방식, 비용 결정 (김승환)
2. 아키텍처와 작업 기반: VPC, 서브넷, 보안 그룹, 엔드포인트 (김태준)
3. WAS: 호환성과 취약점 보완, ARM 기반 배포와 설정 외부화, 가용성 확보와 모니터링 (김건형)
4. DB 서버: RDS MySQL과 RDS Proxy, DB 보안 구성과 데이터 적재 (우수빈)
5. 웹 서버와 CloudFront (양진현)
6. 부하 시험, 최종 결과물, 마무리 (김승환)
7. 시연 (김승환, 김건형)

프로젝트 개요와 서비스 시나리오

동물병원 3,000개 지점을 24시간 운영하는 펫 클리닉의 병원 직원용 홈페이지(PetClinic) 인프라 AWS 구축 의뢰

요구 사항	설계에 반영한 것
서버 한 대 고장 시 5분 이내 정상 서비스	AZ 두 곳에 분산, ALB 상태 확인으로 고장 서버 제외, Auto Scaling으로 교체
AZ 장애 시에도 서비스 지속	다른 AZ 하나만 임시 사용 (영역 이동)
하루 평균 요청 50~800 RPS	웹 `t4g.micro`, WAS `t4g.small`, DB `db.t4g.small`, k6로 검증
고객 정보 저장 시 암호화, 백업	RDS for MySQL 8.4 저장 암호화, DB 구간 TLS, 자동 백업 7일
병원 양식의 오류 페이지	CloudFront 사용자 지정 오류 응답과 S3
Apache, Tomcat, OpenJDK 기반	Apache 2.4, Tomcat 9, Amazon Corretto 8 (OpenJDK 배포판)
사용자 규모 확대	WAS 2~4대 자동 조정, AZ B와 D의 주소 대역 예약

AWS = Amazon Web Services **AZ** = Availability Zone **ALB** = Application Load Balancer **RPS** = Requests Per Second
WAS = Web Application Server **DB** = Database **RDS** = Relational Database Service **TLS** = Transport Layer Security
S3 = Simple Storage Service

팀 구성과 작업 방식

이름	주 담당	부 담당
김태준 (팀장)	작업 기반, IAM	PM
김건형	WAS	DB 서버
김승환	PM, 시나리오, 비용 추산, 부하 시험	웹 서버
양진현	웹 서버	작업 기반
우수빈	DB 서버	WAS

발표는 주 담당 영역을 맡는다. **교차 수행** 검토로 모두가 한 번씩은 절차서에 따라 인프라를 구축해 보았다.

개발용 VPC에서 검증하고 운영용 VPC에 적용

- **개발용 VPC 구축**: 공용(`pet-shared-`) 자원과 개발용(`pet-dev-`) 자원으로 먼저 생성한다.
- **테스트와 검증**: 동작과 근거를 확인한 결정만 남긴다.
- **운영용 VPC 적용**: 운영용(`pet-prod-`) 자원을 절차서대로 생성한다.

IAM = Identity and Access Management **PM** = Project Manager **VPC** = Virtual Private Cloud

일정과 도구

일자	수행 내용
9. 21.	킥오프, 기존 애플리케이션 분석
9. 22. ~ 9. 30.	개발용 VPC 구축과 테스트
10. 1. ~ 10. 8.	운영용 VPC 구축, 테스트 설계와 검증
10. 9. ~ 10. 11.	교차 수행과 절차서 보완
10. 12. ~ 10. 14.	발표 자료 준비, 최종 발표

용도	도구
인프라 구축	AWS 콘솔, CloudShell, Systems Manager
로컬 개발	IntelliJ IDEA, JDK, Tomcat, MySQL
부하 시험	k6
협업	Jira, GitHub
문서화와 발표	Notion, GitHub Wiki, Quarto

JDK = Java Development Kit

비용 추산과 결정

NAT 게이트웨이 대신 엔드포인트

출구 방식	월 고정 요금 (USD)
NAT 게이트웨이 1개	46.72
AZ마다 NAT 게이트웨이 (권장 구성)	93.44
인터페이스 엔드포인트 6개 (선택)	56.94

- NAT 1개보다 고비용이지만, NAT 1개는 해당 AZ 중단 시 다른 AZ의 통신도 차단된다.
- 엔드포인트만 두면 **인터넷으로 나가는 길 자체가 없다**.

인스턴스 유형: Graviton (t4g)

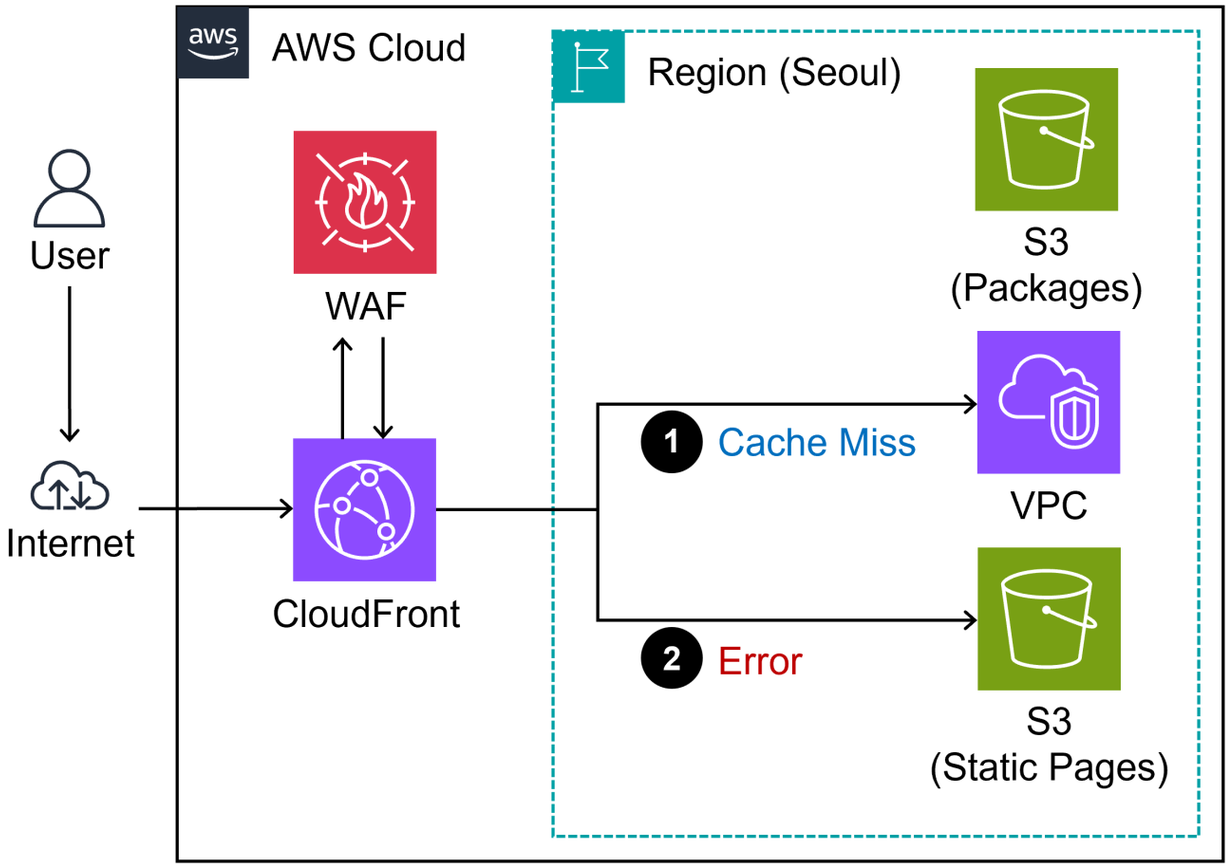
유형	시간당 (USD)
t3.micro / t4g.micro	0.013 / 0.0104
t3.small / t4g.small	0.026 / 0.0208

- 동일한 크기에서 20% 저렴
- 웹은 정적 응답과 전달만 해서 micro, WAS는 JVM 메모리 요구량을 고려해 small

서울 리전, 730시간 기준

NAT = Network Address Translation **JVM** = Java Virtual Machine

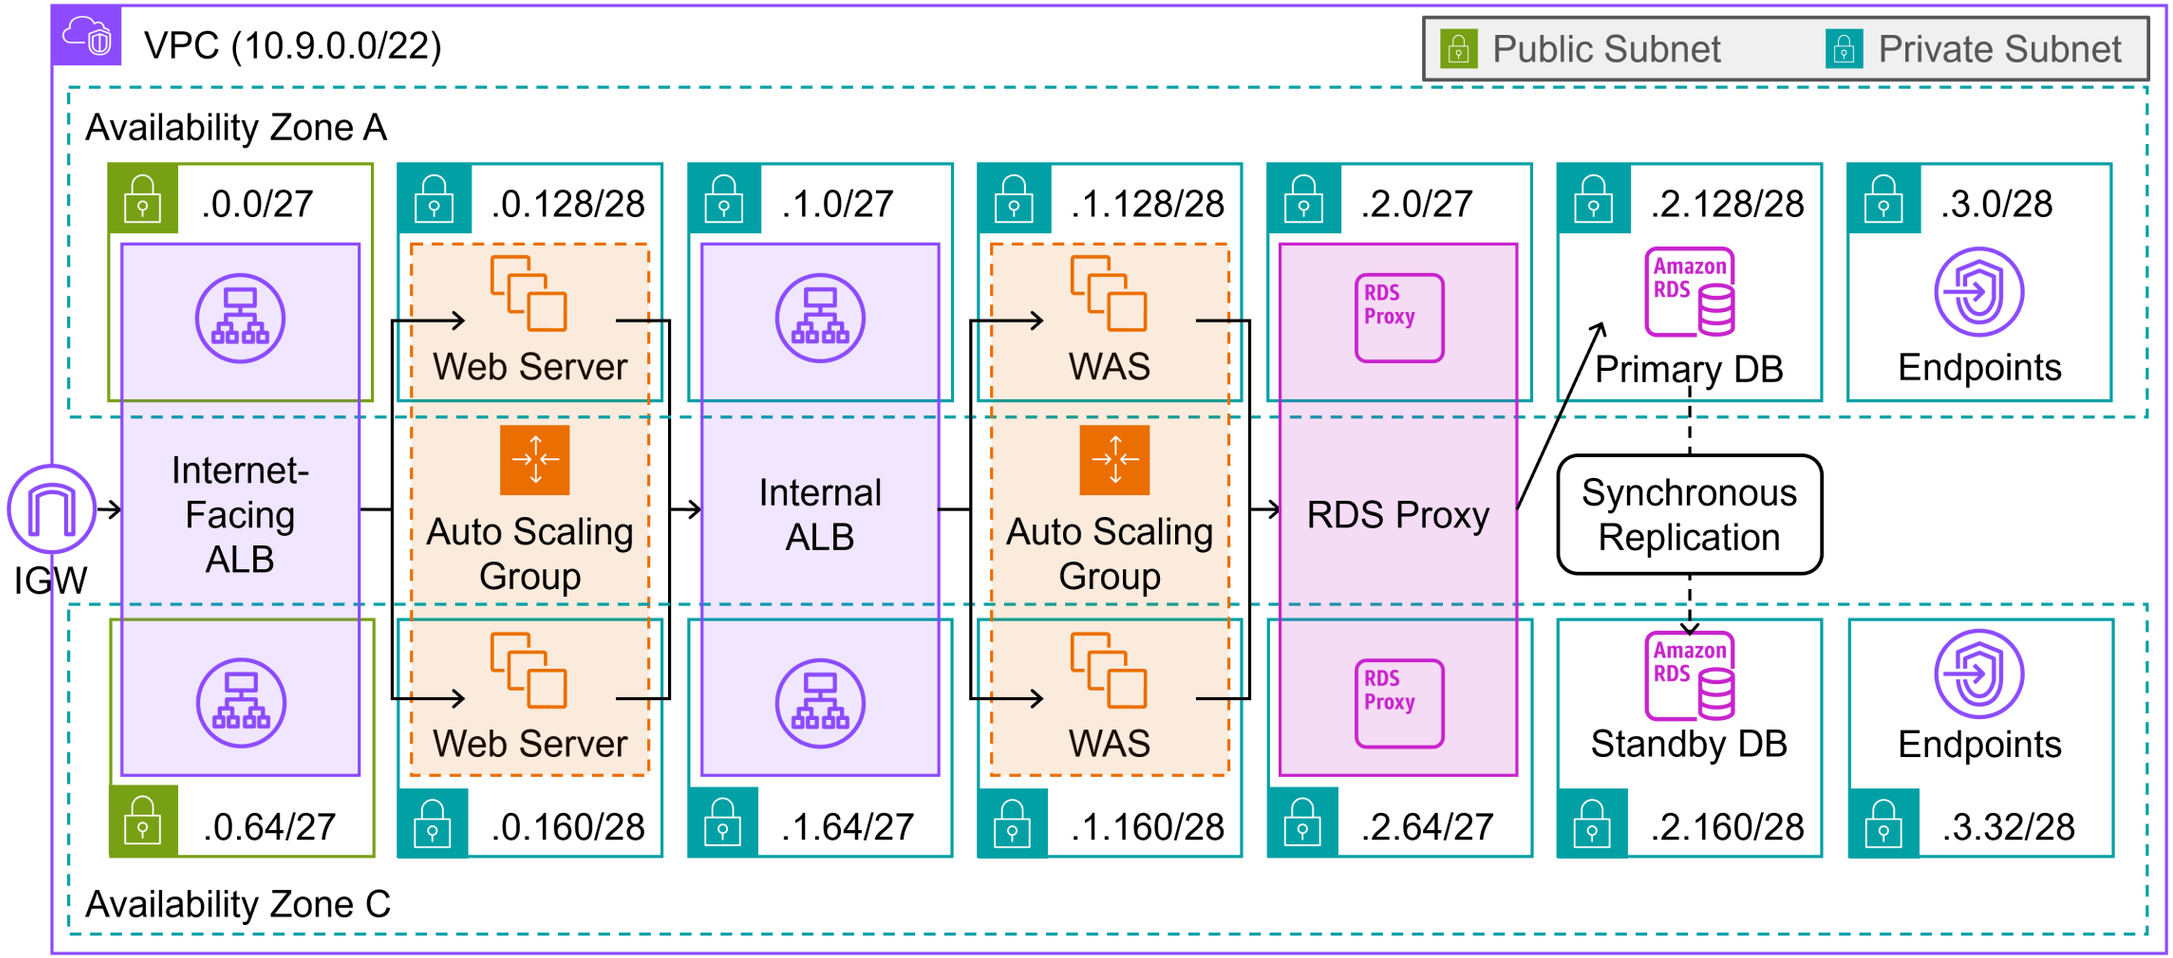
아키텍처: 사용자 요청 경로



- **CloudFront와 WAF**: 사용자 요청을 HTTPS로 받고, WAF가 IP마다 요청 수를 제한한다.
- ① **캐시 미스**: 캐싱을 비활성화했다. 정적 메인 페이지를 포함한 모든 요청이 VPC의 외부 ALB로 전달된다.
- ② **오류**: 오리진이 403, 404, 5xx를 반환하면 S3의 병원 양식 오류 페이지로 응답한다.
- **패키지 버킷 (요청 경로 외)**: 패키지 관리자로 받을 수 없는 패키지를 수동으로 설치할 때 S3 게이트웨이 엔드포인트로 받는다.

WAF = Web Application Firewall **HTTPS** = HTTP Secure **IP** = Internet Protocol

아키텍처: VPC 내부 구성



IGW = Internet Gateway

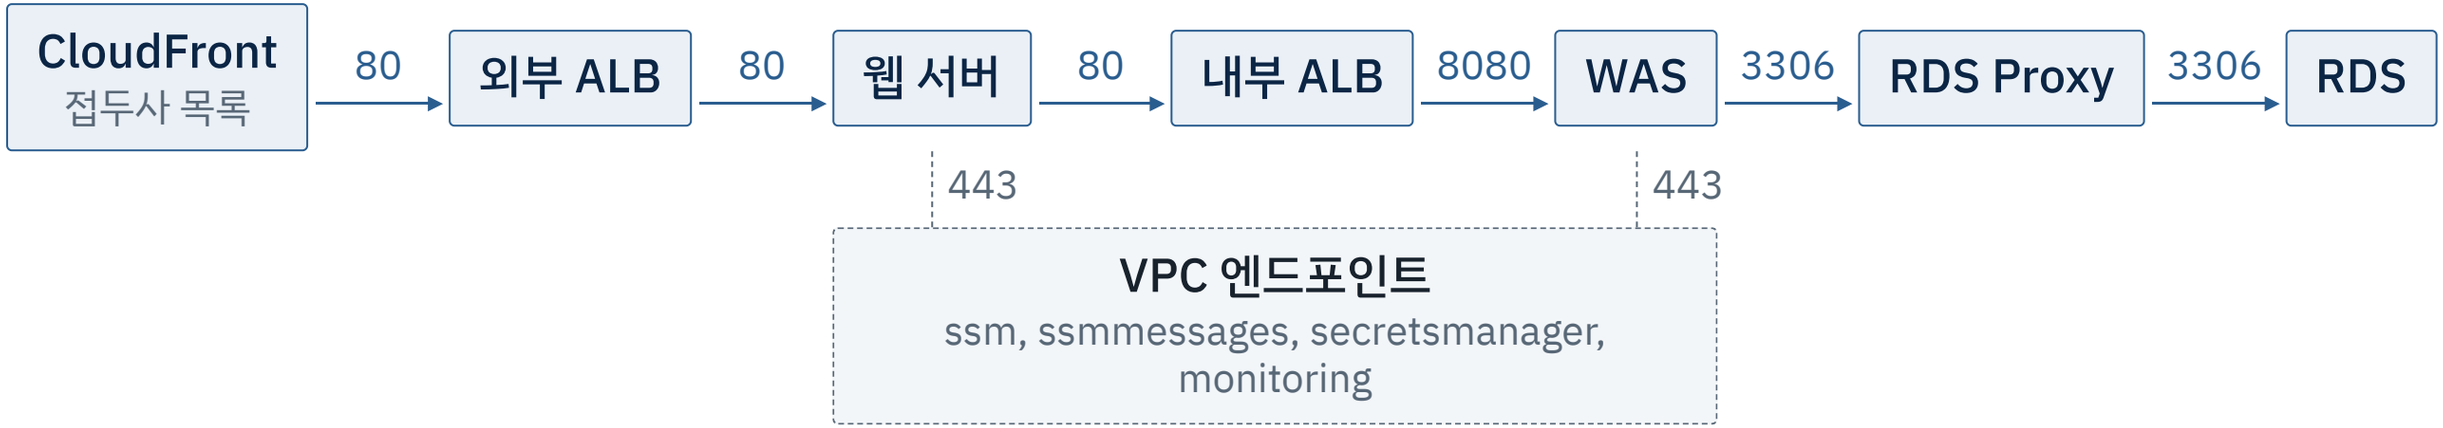
작업 기반: VPC와 서브넷 설계

VPC `10.9.0.0/22`, 서브넷 14개

용도	AZ A	AZ C	AWS 요구 사항
외부 ALB	.0.0/27	.0.64/27	최소 /27 크기 등
웹 서버	.0.128/28	.0.160/28	
내부 ALB	.1.0/27	.1.64/27	최소 /27 크기 등
WAS	.1.128/28	.1.160/28	
RDS Proxy	.2.0/27	.2.64/27	여유 IP 주소 최소 10개
RDS	.2.128/28	.2.160/28	
엔드포인트	.3.0/28	.3.32/28	

- AZ B, D 자리를 **예약해** 향후 AZ 확장이 가능하다.
- 라우팅 테이블 세 개: 퍼블릭(인터넷 게이트웨이), 프라이빗, 엔드포인트

작업 기반: 보안 그룹 사슬과 관리 접속



- 각 계층은 **바로 앞 계층의 보안 그룹이나 접두사 목록**만 소스로 허용한다.
- SSH 포트를 열지 않고 Session Manager로 접속한다. SSM Agent가 엔드포인트로 먼저 연결한다.

SSH = Secure Shell **SSM** = AWS Systems Manager

WAS: 호환성 검토와 취약점 보완

보안

버전 호환성

- 기존 소스와의 호환성을 위해 빌드와 운영 환경을 Java 8로 통일
- Tomcat **9.0.53 → 9.0.122**, Spring Framework **5.3.9 → 5.3.39** 업데이트
- Spring BOM으로 모듈 버전 통일

취약점 보완

- Spring **5.3.39**의 DataBinder 취약점(CVE-2024-38820)에 입력 허용 필드 제한으로 대응
- 다른 보호자의 반려동물 정보가 수정되지 않도록 보호자 관계 검증
- 변경한 기능을 테스트로 검증한 뒤 WAR 파일 빌드

BOM = Bill of Materials **CVE** = Common Vulnerabilities and Exposures **WAR** = Web Application Archive

WAS: ARM 아키텍처 기반 배포와 설정 외부화

비용 최적화

ARM 아키텍처 기반 배포

- AWS가 제공하는 Amazon Linux 2023 사용
- 비용과 효율을 고려해 Graviton 기반 t4g.small 선택
- ARM 아키텍처에서 Java 8과 Tomcat 9.0.122 동작 확인
- AWS Systems Manager로 WAR 배포 후 Petclinic 기동과 DB 연결 검증

운영 설정과 외부화

- EC2 부팅 시 Tomcat 자동 시작
- DB 접속 설정은 Parameter Store에서 조회
- DB 계정 정보는 Secrets Manager JDBC 드라이버로 조회
- 접속 설정 변경 시 WAR 재배포 없이 Tomcat 재기동만으로 반영
- AMI와 시작 템플릿에 서버 설정 반영

EC2 = Elastic Compute Cloud **JDBC** = Java Database Connectivity **AMI** = Amazon Machine Image

WAS: 가용성 확보와 모니터링

안정성과 운영

분산 배치와 자동 확장

- WAS를 가용성을 위해 2a와 2c에 배치
- ALB로 요청 분산 및 헬스 체크
- ASG에 CPU 기준 자동 확장 정책 설정

모니터링과 알림

- CloudWatch Agent로 메모리 사용률 수집
- 정상 WAS가 두 대 미만이면 CloudWatch 경보와 SNS 이메일 알림
- 응답 WAS와 타겟그룹 상태를 보여주는 대시보드 구현

ASG = Auto Scaling Group **CPU** = Central Processing Unit **SNS** = Simple Notification Service

DB 서버: RDS MySQL과 RDS Proxy

안정적인 DB 운영을 위해 **가용성과 연결 안정성**을 중점적으로 고려했다.

RDS for MySQL 8.4

- **Multi-AZ**: AZ 2a Primary / AZ 2c Standby (동기 복제)
- **MySQL 8.4 LTS**: 장기 지원과 유지보수 고려
- **인스턴스**: `db.t4g.small` / gp3 20 GiB
  - 연결 사용률: micro 93% / small 56%
  - 최소 가용 메모리: micro 91 / small 555 MiB
- **데이터 보호**: 자동 백업 7일 / KMS 스토리지 암호화

RDS Proxy

- **연결 경로**: WAS → RDS Proxy → RDS
- **연결 풀링과 재사용**: WAS 확장 시 DB 연결 증가 대응
- **장애 대응**: Multi-AZ 장애 조치 시 DB 연결 복구 지원
  - DB 쿼리 복구 시간: 135초 → 13초
- **TLS 필수**: DB 인증 정보와 전송 데이터 보호

LTS = Long-Term Support **KMS** = Key Management Service

DB 서버: DB 보안 구성과 데이터 적재

계정

계정	용도	자격 증명 관리
마스터 `cloud9`	DB 관리	RDS 관리형 Secret
앱 `cloud9-pet`	PetClinic	Secrets Manager

- **최소 권한**: 앱 계정에 `petclinic` DB의 필요한 권한만 부여
- **인증 정보 관리**: Secrets Manager의 Secret 조회
- **접근 제어**: DB 보안 그룹은 RDS Proxy 보안 그룹의 접근만 허용

적재

- **자동 초기화 방지**: WAR 시작 시 SQL 자동 실행 비활성화
- **별도 적재**: 스키마와 초기 데이터 별도 적재
- **테스트 데이터 10만 건**: owners 2만 / pets 3만 / visits 5만

SQL = Structured Query Language

웹 서버: Apache 리버스 프록시

```
<VirtualHost *:80>
    ProxyAddHeaders On
    ProxyPreserveHost On
    RewriteEngine On
    # /petclinic 으로 오면 /petclinic/ 으로 301
    RewriteRule ^/petclinic$ https://%{HTTP_HOST}/petclinic/ [R=301,L]
    # ttl=55: ALB 유휴 제한(60초)보다 먼저 닫는다
    # addressttl=30: ALB IP가 바뀌어도 30초 안에 다시 조회
    ProxyPass        "/petclinic/" "http://<INTERNAL_ALB_DNS>/petclinic/" ttl=55 addressttl=30
    ProxyPassReverse "/petclinic/" "http://<INTERNAL_ALB_DNS>/petclinic/"
</VirtualHost>
```

- `/petclinic/`만 WAS로 넘기고, 나머지는 Apache가 직접 응답
- 내부 ALB는 IP가 아니라 **DNS 이름**으로 가리킨다.
- SELinux에서 `httpd_can_network_connect` 허용

DNS = Domain Name System **SELinux** = Security-Enhanced Linux

웹 서버: CloudFront와 외부 ALB 보호

CloudFront (정액 요금제 Free)

- 사용자 구간만 HTTPS. ALB에는 인증서가 없어 오리진은 HTTP
- 동적 페이지라 캐싱 비활성화, 쿼리 문자열과 쿠키는 모두 전달
- 오류 시 S3의 공통 오류 페이지 (`/pet_*`, OAC)
- WAF 속도 제한: IP마다 5분에 300건 (현재 모니터 모드)

외부 ALB에 CloudFront만 닿게

1. 보안 그룹: CloudFront 관리형 **접두사 목록**만 허용
2. 리스너: **비밀 헤더**를 포함한 요청만 전달, 나머지는 403

왜 둘 다?

접두사 목록은 **다른 사람의 CloudFront 배포**도 통과시킨다. 비밀 헤더가 우리 배포만 골라낸다.

HTTP = Hypertext Transfer Protocol **OAC** = Origin Access Control

검증: k6 부하 시험

시험 방법

- 인터넷이 없는 ARM 인스턴스라 k6 ARM 실행 파일을 **패키지 버킷으로 반입**
- 테스트 데이터 10만 건 적재 후 시험
- 최대 초당 요청 800건
- 시나리오: 요청 유형 통합 부하 수행

시험 결과

항목	결과
p95 응답 시간	95 ms
응답 실패율	0%
웹 서버	CPU, 메모리 70% 기준 충족
WAS	CPU 70% 기준 초과
RDS	CPU 70% 기준 충족, 가용 메모리 594.73 MiB 추세 확인

p95 = 95번째 백분위수

검증: 부하 시험 지표 (CloudWatch)



위: CPU 사용률(웹 서버, WAS, RDS). 아래: 메모리 사용률(웹 서버, WAS)과 RDS 가용 메모리.

마무리: 배운 점과 남은 과제

배운 점

- 구축보다 **이유를 설명하는 것**이 어렵다. 모든 설정 값에 근거를 기록했다.
- 절차서를 타인이 수행해 보면 누락된 단계가 드러난다.

남은 과제

- ssm 엔드포인트가 AZ A에만 존재하여, AZ A 장애 시 신규 WAS의 설정 조회 실패 가능 → AZ C 추가
- WAF 속도 제한을 모니터 모드에서 **차단 모드로** 전환
- 수작업 구축을 IaC로 옮기기

IaC = Infrastructure as Code

마무리: 최종 결과물

- **설계도**: 3계층, AZ 두 곳, NAT 게이트웨이 없는 구성
- **IP 주소 지도와 보안 그룹**: 서브넷 14개, 앞 계층만 허용하는 보안 그룹 사슬
- **VPC 엔드포인트**: ssm, ssmmessages, secretsmanager, monitoring, S3
- **절차서 (Wiki)**: 구축 단계 전체
  https://github.com/cldnn/petclinic-infra/wiki
- **구축 파일 (저장소)**: 정책 파일, 설정 파일과 그 설명
  https://github.com/cldnn/petclinic-infra
- **WAS 대시보드**: 요청을 처리한 WAS와 대상 상태 → 시연에서 확인

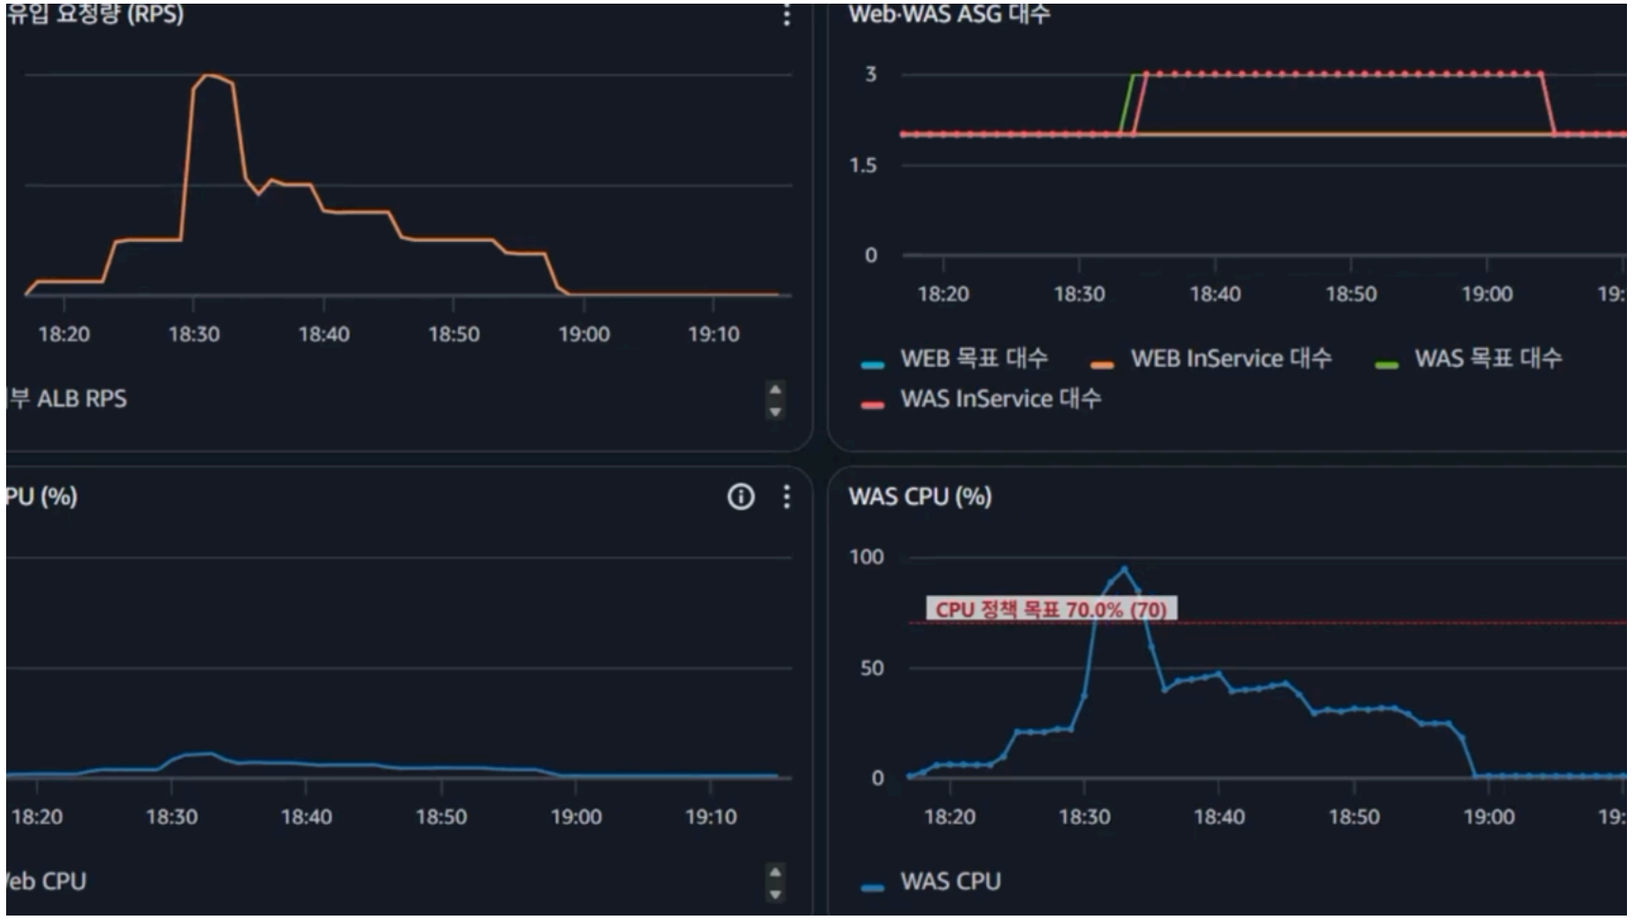
시연: 부하 시험 시나리오

시연 내용: 업무 피크 시간(9시~11시) ASG 확장

24시간 평균 **247.92 RPS**, 1시간 최대 **819.47 RPS** (동물병원 3,000개 지점의 시나리오 더미 데이터)

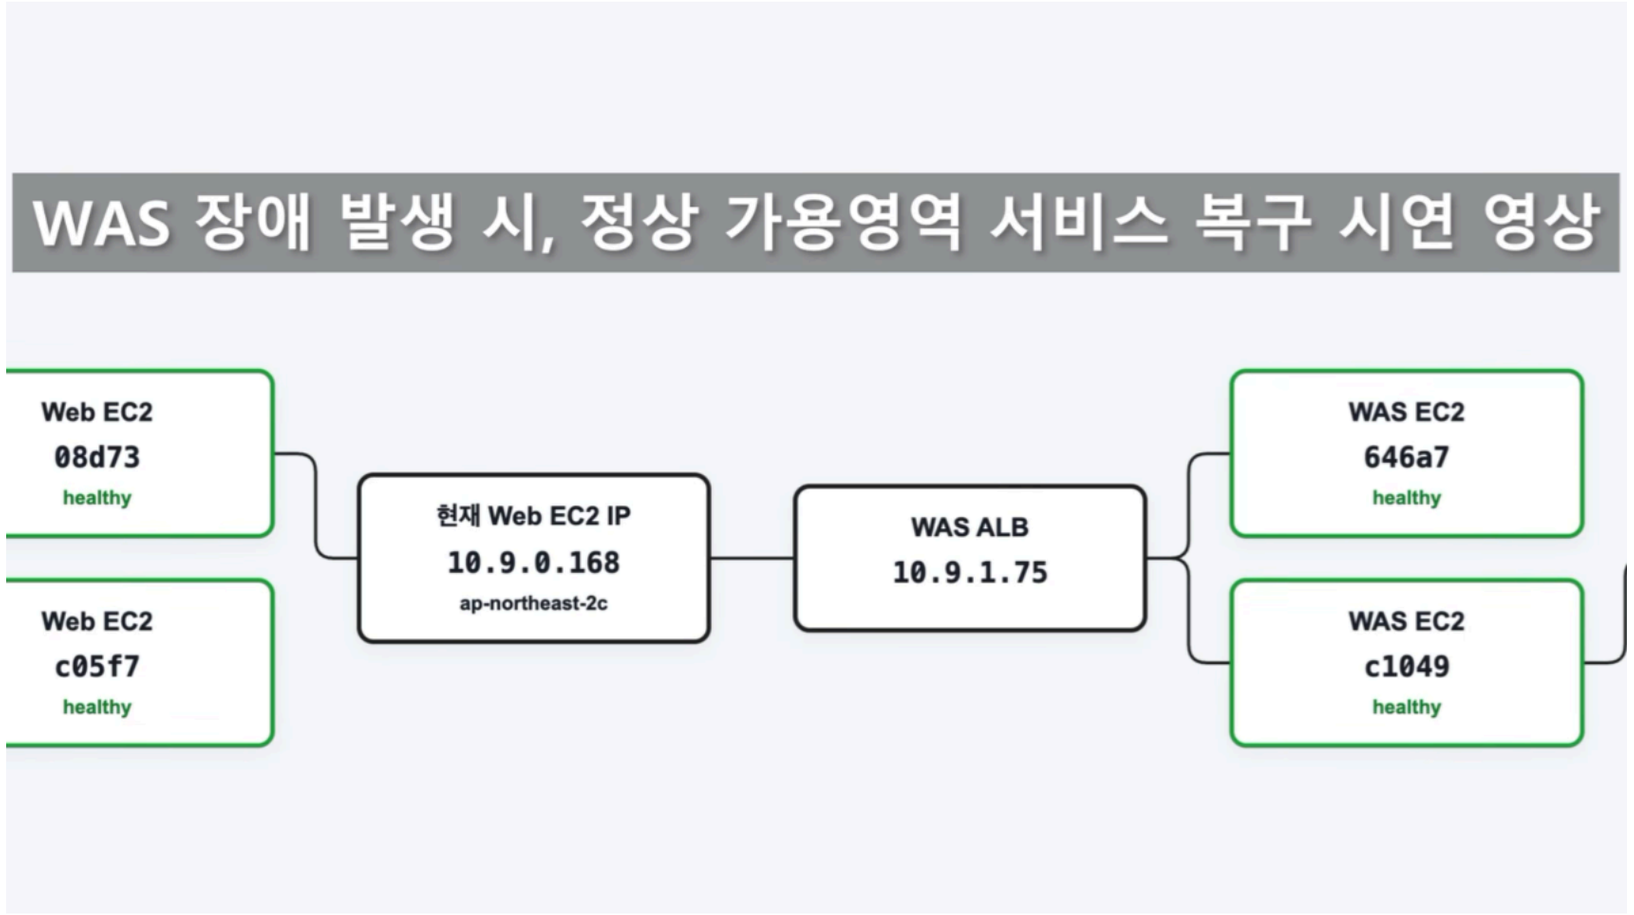


시연: 부하 시험



https://www.youtube.com/watch?v=1ocqK0kxZD0

시연: WAS 장애 시 서비스 복구



https://www.youtube.com/watch?v=tnnP2QoxblA

감사합니다.

Cloud 9: 김태준(팀장), 김건형, 김승환, 양진현, 우수빈

부록

보충 설명용 슬라이드

월 고정 요금 추산 (서울, 730시간)

항목	이 설계의 수량	월 금액 (USD)
RDS DB 인스턴스 (MySQL, Multi-AZ)	`db.t4g.small` 1대	74.46
인터페이스 VPC 엔드포인트	엔드포인트와 AZ 조합 6개	56.94
EC2 인스턴스	웹 micro 2대, WAS small 2대	45.55
ALB	2개, 각 1 LCU로 가정	44.53
RDS Proxy	DB 인스턴스 vCPU 2개	26.28
외부 ALB 공인 IPv4 주소	2개로 추정	7.30
RDS 스토리지 (gp3, Multi-AZ)	20 GB	5.24
EBS 루트 볼륨 (gp3)	8 GB × 4	2.92
Secrets Manager	비밀 2개	0.80
S3 버킷 (오류 페이지, 패키지)	2개, 합계 1 GB로 가정	0.03
합계		**약 264.05**

LCU = Load Balancer Capacity Unit **IPv4** = Internet Protocol version 4 **EBS** = Elastic Block Store

타임아웃 사슬

연결 구간	송신 측 (기본값)	수신 측 (기본값)	조정 방향
CloudFront → 외부 ALB	keep-alive 5초	ALB 유휴 60초	기본값 그대로 안전
외부 ALB → Apache	ALB 유휴 60초	`KeepAliveTimeout` 5초	수신 측을 60초 초과로
Apache → 내부 ALB	mod_proxy `ttl`	ALB 유휴 60초	`ttl`을 60초 미만으로 (`ttl=55`)
내부 ALB → Tomcat	ALB 유휴 60초	`keepAliveTimeout` 20초	수신 측을 60초 초과로
Tomcat → RDS Proxy	커넥션 풀 유휴 연결	유휴 클라이언트 연결 1,800초	풀을 1,800초 미만으로

규칙

한 연결의 양단에서 수신 측의 유휴 시간을 송신 측보다 길게 설정한다. 수신 측이 먼저 연결을 종료하면 이미 종료된 연결로 요청이 전송되어 ALB가 502를 반환한다.

응답 대기 상한은 CloudFront 30초, ALB 60초다. 그러므로 40초가 소요되는 조회는 CloudFront가 먼저 연결을 종료한다. GET과 HEAD는 재시도하고, POST는 재시도하지 않는다.

장애 시 복구 시간

구성	복구 시간 (RTO)에 관련된 사실	데이터 손실 (RPO)에 관련된 사실
Multi-AZ DB 인스턴스 (현재)	장애 조치 보통 60~120초. RDS Proxy가 최대 66% 줄인다.	다른 AZ의 대기 인스턴스로 동기 복제
Multi-AZ DB 클러스터	보통 35초 미만	읽기 인스턴스 하나 이상이 확인해야 커밋
Aurora	복제본 승격 보통 60초 미만	저장 노드 6개에 AZ를 넘어 동기 복제
자동 백업에서 특정 시점 복구	문서에 수치 없음	트랜잭션 로그를 5분마다 S3에 올림. 보존 0~35일

측정한 값

- 장애 조치 시험의 SQL 연결 복구: RDS Proxy 경유 13초, 직접 연결 135초
- 전체 웹 서비스 복구 시간이 아니라 SQL 연결 기준

WAS 서버 하나가 고장 나면

- 상태 확인 20초 간격, 2회 실패로 약 40초 후 대상에서 제외된다.
- 남은 WAS가 요청을 받고, Auto Scaling 그룹이 교체한다.

RTO = Recovery Time Objective **RPO** = Recovery Point Objective

CloudFront 정액 요금제 비교

항목	Free	Pro	Business	Premium
월 요금 (USD)	0	15	200	1,000부터
월 요청 허용량	100만 건	1,000만 건	1억 2,500만 건	5억 건
월 전송 허용량	100 GB	50 TB	50 TB	50 TB
VPC 안의 프라이빗 오리진	미지원	미지원	지원	지원
WAF 규칙 수	5	25	50	75
IP 기반 속도 제한	지원	지원	지원	지원
봇 관리	미지원	미지원	지원	지원
가용성 SLA	미지원	미지원	지원	지원

Free를 선택했다. VPC 오리진은 Business 이상이 필요하므로, internet-facing ALB를 CloudFront 접두사 목록과 비밀 헤더로 이중 차단 했다.

SLA = Service Level Agreement

부하 시험 요청 유형별 적용률

업무	적용률	평균 GET	평균 POST	합계
기존 보호자와 펫 접수	90%	2.7	0	2.7
신규 보호자와 펫 등록	10%	0.4	0.2	0.6
과거 방문 기록 조회	100%	1	0	1
방문 기록 저장	100%	2	1	3
보호자 또는 펫 정보 수정	10%	0.2	0.1	0.3
합계		**6.3**	**1.3**	**7.6**